

第五章 数理统计的基本知识


2025-2026秋季学期



引入

本章转入课程的第二部分

数理统计



Difference between Probability & Statistics

数理统计学

数理统计学是一门应用性很强的学科。它是研究怎样以有效的方式收集、整理和分析带有随机性的数据，以便对所考察的问题作出推断和预测，直至为采取一定的决策和行动提供依据和建议。

数理统计学

数理统计不同于一般的资料统计，它更侧重于应用随机现象本身的规律性进行资料的收集、整理和分析。由于大量随机现象必然呈现出它的规律性，因而从理论上讲，**只要对随机现象进行足够多次观察，被研究的随机现象的规律性一定能清楚地呈现出来。**但客观上只允许我们对随机现象进行次数不多的观察试验，也就是说，我们获得的只是局部观察资料。

数理统计学

数理统计的任务就是研究怎样有效地收集、整理、分析所获得的有限**的资料，对所研究的问题，尽可能地作出精确而可靠的结论。**



数理统计学

数理统计的分类

描述统计学

对随机现象进行观测、试验，以取得有代表性的观测值



推断统计学

Learning in computer science

对已取得的观测值进行整理、分析,作出推断、决策,从而找出所研究的对象的规律性

using data to infer the distribution that generated the data

数理统计学



01 总体与样本

总体与样本

定义：总体——研究对象全体元素组成的集合

所研究的对象的某个(或某些)数量指标的全体，它是一个随机变量(或多维随机变量)，记为 X 。 X 的分布函数和数字特征称为总体的分布函数和数字特征。

个体——组成总体的每一个元素

即总体的每个数量指标，可看作随机变量 X 的某个取值，用 X_i 表示。

例：一个个体 X_i 指一个人，每个人有2维特征{身高、体重}

总体与样本

定义：样本sample —— 从总体中抽取的部分个体.

用 $(X_1, X_2, \dots, X_n)$ 表示, n 为样本容量.

称 $(x_1, x_2, \dots, x_n)$ 为总体 X 的一个容量为 n 的样本观测值, 或称样本的一个实现。

例如：从全体人中抽取了 n 个人, 及 n 个人对应的{身高、体重}

样本空间 —— 样本所有可能取值的集合。

例如：所有人, 所有的特征可能的取值

简单随机样本

若总体 X 的样本 $(X_1, X_2, \dots, X_n)$ 满足:

(1) $X_1, X_2, \dots, X_n$ 与 X 有相同的分布

(2) $X_1, X_2, \dots, X_n$ 相互独立

则称 $(X_1, X_2, \dots, X_n)$ 为简单随机样本.

一般对有限总体, 放回抽样所得到的样本为简单随机样本, 但使用不方便, 常用不放回抽样代替。而代替的条件是总体容量远大于样本容量。

$$N/n \geq 10.$$

总体中个体总数

样本容量

总体与样本

设总体 X 的分布函数为 $F(x)$, 则样本 $X_1, X_2, \dots, X_n$ 的联合分布函数为

$$F_{\text{总}}(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F(x_i)$$

之间独立、
同分布i.i.d.

若总体 X 的d.f.为 $f(x)$ 则样本的联合 d.f.为

$$f_{\text{总}}(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i)$$

总体与样本

例5.1.1 设 $X_1, \dots, X_n$ 为来自总体 $X \sim N(\mu, \sigma^2)$ 的样本, 其中 μ, σ^2 未知。求样本的样本空间和联合密度函数

[解]

$$\Omega = \{ (x_1, \dots, x_n) | x_i \in R, \quad i = 1, 2, \dots, n \}$$

$$\begin{aligned} f(x_1, \dots, x_n) &= \prod_{i=1}^n f(x_i) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} \\ &= \frac{1}{(2\pi)^{\frac{n}{2}} \sigma^n} \cdot e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2} \end{aligned}$$

02 统计量

统计量

定义：统计量

设 $(X_1, X_2, \dots, X_n)$ 是取自总体 X 的一个样本，
 $g(r_1, r_2, \dots, r_n)$ 为一实值连续函数，且不含有未知参数，

则称随机变量 $g(X_1, X_2, \dots, X_n)$ 为**统计量**。

若 $(x_1, x_2, \dots, x_n)$ 是一个样本值，称 $g(x_1, x_2, \dots, x_n)$ 为
统计量 $g(X_1, X_2, \dots, X_n)$ 的一个**样本值**。

统计量与抽样分布

例： $X \sim N(\mu, \sigma^2)$, μ, σ^2 是未知参数

$(X_1, X_2, \dots, X_n)$ 是一样本, 则 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 是统计量, 其中 $X_i \sim N(\mu, \sigma^2)$

但 $\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2$ 不是统计量。若 μ, σ^2 已知, 则为统计量。

随堂测验



设 $X_1, \dots, X_n$ 为来自总体 $X \sim N(\mu, \sigma^2)$ 的样本, 其中 μ, σ^2 未知。下列随机变量中哪些是统计量?

$$T_1 = \frac{1}{n-1} \sum_{i=1}^n X_i;$$

$$T_2 = X_n - EX_1;$$

$$T_3 = 2X_2 + X_3;$$

$$T_4 = \max(X_1, X_2, \dots, X_n);$$

$$T_5 = \frac{X_1 - \mu}{\sigma};$$

$$T_6 = \sum_{i=1}^n \left(\frac{X_i}{\sigma} \right)^2.$$

常用的统计量

设 $(X_1, X_2, \dots, X_n)$ 是来自总体 X 的容量为 n 的样本，称统计量

(1) $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 为**样本均值**(sample mean)

(2) $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} (\sum_{i=1}^n X_i^2 - n\bar{X}^2)$ 为**样本方差**
(sample variance), $S = \sqrt{S^2}$ 为**样本标准差**。

(3) $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 为**样本的 k 阶原点矩(moment)**

例如 $A_1 = \bar{X}$

(4) $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$ 为样本的 k 阶**中心矩**

例如 $B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \triangleq S_n^2 = \frac{n-1}{n} S^2$

常用的统计量

$S^2 = \frac{1}{n-1} (\sum_{i=1}^n X_i^2 - n\bar{X}^2)$ 为样本方差, $S = \sqrt{S^2}$ 为样本标准差

在一些情况下, 样本的方差也用 $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 表示, 相应地标准差用 $S_n = \sqrt{S_n^2}$ 表示, 其中 $S^2 = \frac{1}{n-1} (\sum_{i=1}^n X_i^2 - n\bar{X}^2)$ 是无偏估计量, $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 是有偏估计量。

- 总体已知时, 采用 $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$
- 总体未知, 用样本来估计总体时, 采用 $S^2 = \frac{1}{n-1} (\sum_{i=1}^n X_i^2 - n\bar{X}^2)$

【样本方差分母为什么是n-1\自由度\无偏估计量\公式推导】

https://www.bilibili.com/video/BV1Dq4y1c7zn/?share_source=copy_web&vd_source=f29334cd47f8c16971c64516ce205b6e

常用的统计量

当我们计算样本方差时，我们使用了样本均值 $\bar{X}$ 。而 $\bar{X}$ 是从样本中算出来的，它本身也是一个统计量，会“消耗”一个自由度。

- **自由度 (degrees of freedom)**：在计算统计量时，可以自由变动的数据点个数。

例：假设你有一个样本 X_1, X_2, X_3 ，共 3 个数据。如果你不知道任何信息，你可以自由选择这三个数。但是，如果你已经知道了它们的平均值 $\bar{X} = 5$ ，那么你就不能任意选择三个数了。

- 比如说 $X_1 = 4$ ， $X_2 = 6$ ，那么 X_3 就必须是 5 才能满足平均值为 5。所以实际上只有 2 个数据是“自由”的，第三个被约束了。



因此，虽然有 n 个观测值，但由于用了样本均值 $\bar{X}$ ，我们失去了一个自由度，所以有效自由度是 $n - 1$ 。

常用的统计量

例：考虑以下一组数据{8、18、21、40、60}

- 当总体均值已知为 μ 时，可以通过 $\sum_{i=1}^n (X_i - \mu)^2$ 来计算样本方差
- 当总体均值未知时，可以用样本均值来估计总体均值，通过

$\sum_{i=1}^n (X_i - \bar{X})^2$ 来计算样本方差




$\sum_{i=1}^n (X_i - \mu)^2$ 和 $\sum_{i=1}^n (X_i - \bar{X})^2$ 哪个更大呢？

常用的统计量

例：考虑以下一组数据{8、18、21、40、60}

因为对于样本数据而言，样本均值一定在这些点的中心，而总体均值则不一定，所以 $\sum_{i=1}^n (X_i - \mu)^2 \geq \sum_{i=1}^n (X_i - \bar{X})^2$



常用的统计量

问题转化为：

求 a 取何值时，函数 $f(a) = \sum_{i=1}^n (X_i - a)^2$ 取到极小值？

求函数 $f(a) = \sum_{i=1}^n (X_i - a)^2$ 一阶导， $f'(a)$

$$f(a) = (x_1 - a)^2 + (x_2 - a)^2 + (x_3 - a)^2 + \cdots + (x_n - a)^2$$

$$f'(a) = -(2 \times (x_1 - a) + 2 \times (x_2 - a) + 2 \times (x_3 - a) + \cdots + 2 \times (x_n - a))$$

$$f'(a) = 0$$

$$2 \times (x_1 - a) + 2 \times (x_2 - a) + 2 \times (x_3 - a) + \cdots + 2 \times (x_n - a) = 0$$

$$(x_1 + x_2 + x_3 + \cdots + x_n) - n \times a = 0$$

$$a = \frac{x_1 + x_2 + x_3 + \cdots + x_n}{n} = \bar{x}$$

常用的统计量

设总体方差为 σ^2 ，我们希望找到一个估计量，使得：

$$\mathbb{E}(S^2) = \sigma^2$$

可以证明（下一页）：

$$\mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \frac{n-1}{n} \sigma^2 < \sigma^2$$

也就是说，如果用 $\frac{1}{n}$ ，结果会**系统性地低估**总体方差。

但如果用：

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

则有：

$$\mathbb{E}(S^2) = \sigma^2$$

所以它是无偏估计量



常用的统计量

$$\mathbb{E} \left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \right) = \frac{n-1}{n} \sigma^2 < \sigma^2$$

证明:

$$\begin{aligned} \sum_{i=1}^n (X_i - \bar{X})^2 &= \sum_{i=1}^n [(X_i - \mu) - (\bar{X} - \mu)]^2 \\ &= \sum_{i=1}^n \left[(X_i - \mu)^2 - 2(X_i - \mu)(\bar{X} - \mu) + (\bar{X} - \mu)^2 \right] \\ &= \sum_{i=1}^n (X_i - \mu)^2 - 2(\bar{X} - \mu) \sum_{i=1}^n (X_i - \mu) + n(\bar{X} - \mu)^2 \\ &= \sum_{i=1}^n (X_i - \mu)^2 - 2n(\bar{X} - \mu)^2 + n(\bar{X} - \mu)^2 \\ &= \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2 \end{aligned}$$

$\sum_{i=1}^n (X_i - \mu) = \sum_{i=1}^n X_i - n\mu = n\bar{X} - n\mu$

常用的统计量

$$\mathbb{E} \left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \right) = \frac{n-1}{n} \sigma^2 < \sigma^2$$

证明:

$$E \left(\sum_{i=1}^n (X_i - \bar{X})^2 \right) = E \left[\sum_{i=1}^n (X_i - \mu)^2 \right] - E[n(\bar{X} - \mu)^2]$$

第一项:

$$E \left[\sum_{i=1}^n (X_i - \mu)^2 \right] = \sum_{i=1}^n E(X_i - \mu)^2 = \sum_{i=1}^n \text{Var}(X_i) = n\sigma^2$$

第二项:

$$E[n(\bar{X} - \mu)^2] = nE(\bar{X} - \mu)^2 = n\text{Var}(\bar{X})$$

$$\text{Var}(\bar{X}) = \text{Var} \left(\frac{1}{n} \sum_{i=1}^n X_i \right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n}$$

$$\text{因此 } E \left(\sum_{i=1}^n (X_i - \bar{X})^2 \right) = n\sigma^2 - \sigma^2 = (n-1)\sigma^2$$

$$E \left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \right) = \frac{n-1}{n} \sigma^2 < \sigma^2$$

常用的统计量

$S^2 = \frac{1}{n-1} (\sum_{i=1}^n X_i^2 - n\bar{X}^2)$ 为样本方差, $S = \sqrt{S^2}$ 为样本标准差

在一些情况下, 样本的方差也用 $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 表示, 相应地标准差用 $S_n = \sqrt{S_n^2}$ 表示。

$$S^2 = \frac{n}{n-1} S_n^2, E(S_n^2) = \frac{n-1}{n} D(X), E(S^2) = D(X)$$

推导过程: $S^2 = \frac{n}{n-1} S_n^2$

$$\begin{aligned} \sum_{i=1}^n (X_i - \bar{X})^2 &= \sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2) = \sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + \sum_{i=1}^n \bar{X}^2 \\ &= \sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2 \end{aligned}$$

常用的统计量

$S^2 = \frac{1}{n-1} (\sum_{i=1}^n X_i^2 - n\bar{X}^2)$ 为样本方差, $S = \sqrt{S^2}$ 为样本标准差

在一些情况下, 样本的方差也用 $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 表示, 相应地标准差用 $S_n = \sqrt{S_n^2}$ 表示。 $S^2 = \frac{n}{n-1} S_n^2, E(S_n^2) = \frac{n-1}{n} D(X), E(S^2) = D(X)$

推导过程: $E(S_n^2) = \frac{n-1}{n} D(X)$

易知 $E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = E(X), D(\bar{X}) = \frac{1}{n} D(X)$

$$\begin{aligned} E(S_n^2) &= E\left(\frac{1}{n} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right)\right) = E\left(\frac{1}{n} \sum_{i=1}^n X_i^2\right) - [D(\bar{X}) + E^2(\bar{X})] \\ &= \frac{1}{n} \sum_{i=1}^n E(X_i^2) - \frac{1}{n} DX - E^2 X = \frac{1}{n} \sum_{i=1}^n (DX + E^2 X) - \frac{1}{n} DX - E^2 X \\ &= DX + E^2 X - \frac{1}{n} DX - E^2 X = \frac{n-1}{n} DX \end{aligned}$$

常用的统计量


$S^2 = \frac{1}{n-1} (\sum_{i=1}^n X_i^2 - n\bar{X}^2)$ 为样本方差, $S = \sqrt{S^2}$ 为样本标准差

在一些情况下, 样本的方差也用 $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 表示, 相应地标准差用 $S_n = \sqrt{S_n^2}$ 表示。

$$S^2 = \frac{n}{n-1} S_n^2, E(S_n^2) = \frac{n-1}{n} D(X), E(S^2) = D(X)$$

推导过程: $E(S^2) = D(X)$

$$E(S^2) = E\left[\frac{n}{n-1} S_n^2\right] = \frac{n}{n-1} E S_n^2 = D(X)$$



常用的统计量

例5.2.1 设 $X_1, X_2, \dots, X_n$ 是来自泊松分布 $P(\lambda)$ 的样本,
 $\bar{X}, S^2$ 分别为样本均值和样本方差, 求 $E(\bar{X}), D(\bar{X}), E(S^2)$



常用的统计量

例5.2.1 设 $X_1, X_2, \dots, X_n$ 是来自泊松分布 $P(\lambda)$ 的样本, $\bar{X}, S^2$ 分别为样本均值和样本方差, 求 $E(\bar{X}), D(\bar{X}), E(S^2)$

[解]

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n x_i\right) = E(X) = \lambda$$

$$D(\bar{X}) = \frac{1}{n} D(X) = \frac{\lambda}{n}$$

$$E(S^2) = D(X) = \lambda$$



03 三大分布

抽样分布

统计量既然是依赖于样本的，而后者又是随机变量，故统计量也是随机变量，因而就有一定的分布，这个分布叫做统计量的抽样分布。



统计中常用分布

(1) 正态分布

若 $X_1, X_2, \dots, X_n \sim N(\mu_i, \sigma_i^2)$, 则

$$\sum_{i=1}^n a_i X_i \sim N\left(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2\right)$$

特别地, 若 $X_1, X_2, \dots, X_n$ 独立同分布 (i.i.d) 且 $X_i \sim N(\mu, \sigma^2)$

则 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$ 或 $\sum_{k=1}^n X_k \sim N(n\mu, n\sigma^2)$ 或

$$Y_n = \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \sim N(0, 1)$$

统计中常用分布

(2) χ^2 分布 (卡方分布)

χ^2 分布是由正态分布派生出来的一种分布。

定义：设 $X_1, \dots, X_n$ 相互独立，都服从正态分布 $N(0,1)$ ，则称随机变量：

$$\chi^2 = X_1^2 + X_2^2 + \dots + X_n^2$$


所服从的分布为自由度为 n 的 χ^2 分布，记为 $\chi^2 \sim \chi^2(n)$

统计中常用分布

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

$n = 1$ 时, $\chi^2 = X_1^2$, 其密度函数为

$$f(x) = \begin{cases} \frac{1}{\sqrt{2\pi}} x^{-\frac{1}{2}} e^{-\frac{x}{2}} = \frac{1}{\sqrt{2\pi x}} e^{-\frac{x}{2}}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$



统计中常用分布

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

推导过程: $Z \sim N(0,1)$, 令: $X = Z^2$ 求 X 的概率密度函数 $f_X(x)$
对于 $x > 0$:

$$\begin{aligned} F_X(x) &= P(X \leq x) = P(Z^2 \leq x) = P(-\sqrt{x} \leq Z \leq \sqrt{x}) \\ &= \Phi(\sqrt{x}) - \Phi(-\sqrt{x}) = 2\Phi(\sqrt{x}) - 1 \end{aligned}$$

$$f_X(x) = \frac{d}{dx} F_X(x) = \frac{d}{dx} [2\Phi(\sqrt{x}) - 1] = 2 \cdot \phi(\sqrt{x}) \cdot \frac{d}{dx} (\sqrt{x})$$

其中:

- $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ 是标准正态密度
- $\frac{d}{dx} \sqrt{x} = \frac{1}{2\sqrt{x}}$

$$\text{代入: } f_X(x) = 2 \cdot \frac{1}{\sqrt{2\pi}} e^{-(\sqrt{x})^2/2} \cdot \frac{1}{2\sqrt{x}} = \frac{1}{\sqrt{2\pi}} \cdot \frac{e^{-x/2}}{\sqrt{x}}$$


$$f(x) = \begin{cases} \frac{1}{\sqrt{2\pi x}} e^{-x/2}, & x > 0 \\ 0, & x < 0 \end{cases}$$

统计中常用分布

$n = 2$ 时,其密度函数为

$$f(x) = \begin{cases} \frac{1}{2} e^{-\frac{x}{2}}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

为参数为1/2的指数分布.



统计中常用分布

自由度为 n 的 $\chi^2(n)$ 的密度函数为

$$f(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} e^{-\frac{x}{2}} x^{\frac{n}{2}-1}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

其中, $\Gamma(x) = \int_0^{+\infty} t^{x-1} e^{-t} dt$


在 $x > 0$ 时收敛, 称为 Γ 函数, 具有性质

$$\Gamma(x+1) = x\Gamma(x), \quad \Gamma(1) = 1, \quad \Gamma(1/2) = \sqrt{\pi}$$

$$\Gamma(n+1) = n! \quad (n \in N)$$



统计中常用分布



统计中常用分布

重要

χ^2 分布的性质:

1° $E(\chi^2(n)) = n, D(\chi^2(n)) = 2n$

2° 若 $X_1 = \chi^2(n_1), X_2 = \chi^2(n_2)$, X_1, X_2 相互独立,
则 $X_1 + X_2 \sim \chi^2(n_1 + n_2)$

3° $n \rightarrow \infty$ 时, $\chi^2(n) \rightarrow$ 正态分布



统计中常用分布

对于给定的 $\alpha (0 < \alpha < 1)$, 称满足条件:



$$P\{\chi^2 > \chi_{\alpha}^2(n)\} = \alpha$$

的点 $\chi_{\alpha}^2(n)$ 为 $\chi^2(n)$ 分布的上 α 分位点。

例如

$$\chi_{0.05}^2(10) = 18.307$$

$$P(\chi^2(10) > 18.307) = 0.05$$



统计中常用分布

重要

χ^2 分布的应用:

想象你在做实验，每次测量都有随机误差（服从正态分布）。

你想知道这些误差“整体上大不大”。

- 你不能直接加误差（正负抵消），所以你平方后再加。
- 这个“平方和”就服从卡方分布。

➤ 检验方差

比如：一台机器生产的零件长度标准差应该是 0.5cm，现在你抽样发现样本方差很大，是偶然还是真变差了？→ 用 χ^2 检验方差。

➤ 拟合优度检验 (Goodness-of-fit)

比如：你抛了 100 次硬币，结果是 60 次正面。这枚硬币是公平的吗？→ 把“实际频数 vs 期望频数”的差异平方和，构造一个卡方统计量。

卡方分布的核心思想：把“差异”平方后加起来，看这个“总差异”大不大。

统计中常用分布

重要

(3) t 分布 (Student 分布)


$X \sim N(0,1)$, $Y \sim \chi^2(n)$, X, Y 独立, 则称随机变量

$$T = \frac{X}{\sqrt{\frac{Y}{n}}}$$

为服从自由度是 n 的 t - 分布, 记作 $T \sim t(n)$.

其密度函数为 $f(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}} \quad -\infty < t < \infty$

统计中常用分布



t 分布的图形(红色的是标准正态分布)

统计中常用分布

t 分布的性质

重要

$f_n(t)$ 是偶函数, $n \rightarrow \infty, f_n(t) \rightarrow \phi(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}$


不难看到, 当 n 充分大时, t 分布近似 $N(0, 1)$ 分布.
但对于较小的 n , t 分布与 $N(0, 1)$ 分布相差很大.

统计中常用分布

对于给定的 $\alpha (0 < \alpha < 1)$, 称满足条件:

$$P\{t > t_{\alpha}(n)\} = \alpha$$

的点 $t_{\alpha}(n)$ 为t分布的上 α 分位点。



由概率密度的对称性知: $t_{1-\alpha}(n) = -t_{\alpha}(n)$



统计中常用分布

重要

t 分布的应用:

你想知道样本均值 $\bar{X}$ 和假设的总体均值 μ 之间的差异是否显著。如果你知道总体标准差 σ ，那就用正态分布 $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$ 来计算。

- 但现实中，你不知道 σ ，只能用样本标准差 S 来估计它
- 用 S 代替 σ ，就引入了额外的不确定性 $\rightarrow$ 分布就不再是正态，而是 **t 分布**

所以：**t 分布 = 当你用样本标准差估计总体标准差时，均值差异的分布**

➤ 小样本均值检验 (t 检验)

比如：新药是否有效？你只测试了 10 个人，样本均值比以前高，是真的有效吗？用 t 检验，因为样本小， S 不太准，要用 t 分布来“保守一点”

t 分布的核心思想：**小样本时，我们对标准差也不确定，所以要“放宽”判断标准。**

统计中常用分布

(4) F 分布

重要

若 $X \sim \chi^2(n_1)$, $Y \sim \chi^2(n_2)$, X, Y 独立, 则称随机变量

$F = \frac{X/n_1}{Y/n_2}$ 为服从自由度是 n_1, n_2 的 F 分布, 记作

$F \sim F(n_1, n_2)$.



统计中常用分布


重要

若 $F \sim F(n_1, n_2)$, X 的概率密度为

$$f(x) = \begin{cases} \frac{\Gamma\left(\frac{n_1 + n_2}{2}\right)}{\Gamma\left(\frac{n_1}{2}\right) \Gamma\left(\frac{n_2}{2}\right)} \left(\frac{n_1}{n_2}\right) \left(\frac{n_1}{n_2} x\right)^{\frac{n_1}{2}-1} \left(1 + \frac{n_1}{n_2} x\right)^{-\frac{n_1+n_2}{2}}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

F分布的性质由定义可见, 若

$F \sim F(n_1, n_2)$, 则 $\frac{1}{F} \sim F(n_2, n_1)$.




统计中常用分布

对于给定的 $\alpha (0 < \alpha < 1)$, 称满足条件:

$$P\{F > F_{\alpha}(n_1, n_2)\} = \alpha$$

的点 $F_{\alpha}(n_1, n_2)$ 为F分布的上 α 分位点。

重要



结论: $F_{1-\alpha}(n_1, n_2) = 1/F_{\alpha}(n_2, n_1)$



统计中常用分布

证明 $F_{1-\alpha}(n, m) = \frac{1}{F_{\alpha}(m, n)}$

证：根据分位点定义

$$\begin{aligned} F_{1-\alpha}(n, m) &\Rightarrow P(F^{n,m} \geq F_{1-\alpha}(n, m)) = P\left(\frac{1}{F^{n,m}} \leq \frac{1}{F_{1-\alpha}(n, m)}\right) \\ &= 1 - P\left(\frac{1}{F^{n,m}} \geq \frac{1}{F_{1-\alpha}(n, m)}\right) = 1 - \alpha \\ \therefore P\left(\frac{1}{F^{n,m}} \geq \frac{1}{F_{1-\alpha}(n, m)}\right) &= \alpha \because \frac{1}{F^{n,m}} \sim F(m, n) \\ \therefore P\left(F^{m,n} \geq \frac{1}{F_{1-\alpha}(n, m)}\right) &= \alpha \text{ 又 } \because F_{\alpha}(m, n) \Rightarrow P(F^{m,n} \geq F_{\alpha}(m, n)) = \alpha \\ \text{因而 } \frac{1}{F_{1-\alpha}(n, m)} &= F_{\alpha}(m, n) \end{aligned}$$

数理统计学

统计中常用分布

$$\chi^2_{0.9}(16) = 9.312,$$

$$\chi^2_{0.95}(16) = 7.962,$$

$$\chi^2_{0.10}(16) = 23.542,$$

$$\chi^2_{0.05}(16) = 26.296$$

附表6 χ^2 分布表

$P(\chi^2(n) \geq \chi^2_{\alpha}(n)) = \alpha$




n	α					
	0.995	0.99	0.975	0.95	0.90	0.75
1	—	—	0.001	0.004	0.016	0.102
2	0.010	0.020	0.051	0.103	0.211	0.575
3	0.072	0.115	0.216	0.352	0.584	1.213
4	0.207	0.297	0.484	0.711	1.064	1.923
5	0.412	0.554	0.831	1.145	1.610	2.675
11	2.603	3.053	3.816	4.575	5.578	7.584
12	3.074	3.571	4.404	5.226	6.304	8.438
13	3.565	4.107	5.009	5.892	7.042	9.299
14	4.075	4.660	5.629	6.571	7.790	10.165
15	4.601	5.229	6.262	7.261	8.547	11.037
16	5.142	5.812	6.908	7.962	9.312	11.912
17	5.697	6.408	7.564	8.672	10.085	12.792
18	6.265	7.015	8.231	9.390	10.865	13.675
19	6.844	7.633	8.907	10.117	11.651	14.562

n	α					
	0.25	0.10	0.05	0.025	0.01	0.005
16	19.369	23.542	26.296	28.845	32.000	34.267
17	20.489	24.769	27.587	30.191	33.409	35.718
18	21.605	25.989	28.869	31.526	34.805	37.156
19	22.718	27.204	30.144	32.852	36.191	38.582
20	23.828	28.412	31.410	34.170	37.566	39.997

统计中常用分布——查表

$t_{0.95}(20) = -1.7247$
 $t_{0.05}(20) = 1.7247$

<i>n</i>	<i>α</i>					
	0.25	0.10	0.05	0.025	0.01	0.005
1	1.000 0	3.077 7	6.313 8	12.706 2	31.820 7	63.657 4
2	0.816 5	1.885 6	2.920 0	4.302 7	6.964 6	9.924 8
18	0.688 4	1.330 4	1.734 1	2.100 9	2.552 4	2.878 4
19	0.687 6	1.327 7	1.729 1	2.093 0	2.539 5	2.860 9
20	0.687 0	1.325 3	1.724 7	2.086 0	2.528 0	2.845 3
21	0.686 4	1.323 2	1.720 7	2.079 6	2.517 7	2.831 4



统计中常用分布——查表

$$F_{0.95}(4,6) = \frac{1}{F_{0.05}(6,4)} = \frac{1}{6.16} = 0.1623$$
$$F_{0.05}(4,6) = 4.53$$

α	n	m																
		1	2	3	4	5	6	7	8	9	10	12	15	20	30	60	120	∞
0.10	4	4.54	4.32	4.19	4.11	4.05	4.01	3.98	3.95	3.93	3.92	3.90	3.87	3.84	3.82	3.79	3.78	3.76
0.05		7.71	6.94	6.59	6.39	6.26	6.16	6.09	6.04	6.00	5.96	5.91	5.86	5.80	5.75	5.69	5.66	5.63
0.025		12.2	10.6	9.98	9.60	9.36	9.20	9.07	8.98	8.90	8.84	8.75	8.66	8.56	8.46	8.36	8.31	8.26
0.01		21.2	18.0	16.7	16.0	15.5	15.2	15.0	14.8	14.7	14.5	14.4	14.2	14.0	13.8	13.7	13.6	13.5
0.005		31.3	26.3	24.3	23.2	22.5	22.0	21.6	21.4	21.1	21.0	20.7	20.4	20.2	19.9	19.6	19.5	19.3
0.10	5	4.06	3.78	3.62	3.52	3.45	3.40	3.37	3.34	3.32	3.30	3.27	3.24	3.21	3.17	3.14	3.12	3.11
0.05		6.61	5.79	5.41	5.19	5.05	4.95	4.88	4.82	4.77	4.74	4.68	4.62	4.56	4.50	4.43	4.40	4.37
0.025		10.0	8.43	7.76	7.39	7.15	6.98	6.85	6.76	6.68	6.62	6.52	6.43	6.33	6.23	6.12	6.07	6.02
0.01		16.3	13.3	12.1	11.4	11.0	10.7	10.5	10.3	10.2	10.1	9.89	9.72	9.55	9.38	9.20	9.11	9.02
0.005		22.8	18.3	16.5	15.6	14.9	14.5	14.2	14.0	13.8	13.6	13.4	13.1	12.9	12.7	12.4	12.3	12.1
0.10	6	3.78	3.46	3.29	3.18	3.11	3.05	3.01	2.98	2.96	2.94	2.90	2.87	2.84	2.80	2.76	2.74	2.72
0.05		5.99	5.14	4.76	4.53	4.39	4.28	4.21	4.15	4.10	4.06	4.00	3.94	3.87	3.81	3.74	3.70	3.67
0.025		8.81	7.26	6.60	6.23	5.99	5.82	5.70	5.60	5.52	5.46	5.37	5.27	5.17	5.07	4.96	4.90	4.85
0.01		13.7	10.9	9.78	9.15	8.75	8.47	8.26	8.10	7.98	7.87	7.72	7.56	7.40	7.23	7.06	6.97	6.88
0.005		18.6	14.5	12.9	12.0	11.5	11.1	10.8	10.6	10.4	10.2	10.0	9.81	9.59	9.36	9.12	9.00	8.88

统计中常用分布

F分布的应用：

你想比较两个群体的“波动性”，比如A班和B班的考试成绩，哪个班更“两极分化”？

- 你不能直接比样本方差 S_1^2 和 S_2^2 ，因为有随机性
- 所以你构造一个比值： $F = \frac{S_1^2}{S_2^2}$ ，这个比值在“方差相等”时应该接近 1
- 如果远大于 1 或远小于 1，就说明不相等

F分布 = 两个方差的比值分布

➤ **两个总体方差是否相等 (F 检验)**


比如：两种测量仪器，哪个更稳定？→ 比较它们的方差

➤ **方差分析 (ANOVA)**

比如：三种教学方法，哪种效果最好？你不是直接比均值，而是看“组间差异” vs “组内差异”，这个比值服从 F 分布 → F 检验

F 分布的核心思想：把系统性差异和随机误差做个比值，看是不是大到不能用偶然解释。

统计中常用分布总结



统计中常用分布总结

分布	计算方式	实际用途
χ^2 分布	标准正态变量的平方和	检验“方差”、检验“分布是否符合预期”
t 分布	标准正态 / 根号下 χ^2/n	小样本下，检验“均值”
F 分布	两个 χ^2 的比值	比较“两个方差”，或多组均值是否相等

- χ^2 探测 “分布是否异常”
- t 探测 “均值是否显著不同”
- F 探测 “方差或组间差异是否显著”

04 正态总体的抽样分布

总体的抽样

从一个无限总体独立、随机抽样可以得到无穷多个样本，构成一个新总体。可以以样本平均数、总和数等统计数作为由抽样产生的随机变量。





图 4-14 总体和样本的关系

总体的抽样

某杂交稻品种：一般产量450公斤/亩（参数），种植 n 块（样本），可以种植无穷多个 n 块，构成总体。

地方农家品种：一般产量200公斤/亩（参数），种植 n 块（样本），可以种植无穷多个 n 块，构成总体。

总体与样本的关系



正态总体的抽样分布

在正态总体的条件下，某些样本的常见统计量有比较简单的计算方式。

(I) 一个正态总体

定理5.3.1 设 $X_1, \dots, X_n$ 是总体 $N(\mu, \sigma^2)$ 的样本， $\bar{X}, S^2$ 分别是样本均值与样本方差，则有：

$$(1) \bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right), \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

$$(2) \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

$$(3) \bar{X} \text{ 与 } S^2 \text{ 独立}$$

$$(4) \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$



正态总体的抽样分布

(1) 证明：设 $X_1, \dots, X_n$ 是总体 $N(\mu, \sigma^2)$ 的样本， $\bar{X}, S^2$ 分别是样本均值与样本方差，则有： $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right), \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$

$\because \sum_{i=1}^n X_i$ 是相互独立的正态分布的和

$\therefore \sum_{i=1}^n X_i$ 也服从正态分布

$$\because E\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n E(X_i) = n\mu \quad D\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n D(X_i) = n\sigma^2$$

$$\therefore \sum_{i=1}^n X_i \sim N(n\mu, n\sigma^2), \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

将 $\bar{X}$ 标准化 $U = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$

也可以根据中心极限定理来理解

正态总体的抽样分布

(2) 证明：设 $X_1, \dots, X_n$ 是总体 $N(\mu, \sigma^2)$ 的样本， $\bar{X}, S^2$ 分别是样本均值与样本方差，则有： $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$

令 $Z_i = \frac{X_i - \mu}{\sigma} (i = 1, 2, \dots, n)$

则 $Z_1, \dots, Z_n$ 相互独立，且都服从 $N(0, 1)$ 。从而

$$\bar{Z} = \frac{1}{n} \sum_{i=1}^n Z_i = \frac{\bar{X} - \mu}{\sigma}$$

$$\begin{aligned} \frac{(n-1)S^2}{\sigma^2} &= \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} = \sum_{i=1}^n \left[\frac{(X_i - \mu) - (\bar{X} - \mu)}{\sigma} \right]^2 \\ &= \sum_{i=1}^n (Z_i - \bar{Z})^2 = \sum_{i=1}^n Z_i^2 - n\bar{Z}^2 \end{aligned}$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

正态总体的抽样分布

将随机变量写成列向量的形式 $Z = \begin{pmatrix} Z_1 \\ \vdots \\ Z_n \end{pmatrix} \in R^n$, 这个列向量被称

为 n 维随机变量向量。若一个随机向量 $Z \in R^n$ 的任意线性组合 $a^T Z (a \in R^n)$ 都服从一元正态分布, 则称 Z 服从 **多元正态分布**。

记作: $Z \sim N_n(\mu, \Sigma)$, 其中

- $\mu = E[Z] \in R^n$ 表示均值向量
- $\Sigma = Cov(Z) \in R^{n \times n}$ 表示协方差矩阵, $\Sigma_{ij} = Cov(Z_i, Z_j) = E[(Z_i - \mu_i)(Z_j - \mu_j)]$

例如一个二元正态分布的参数为 $\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$, $\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix}$

应用到本例, 每个 $Z_i \sim N(0, 1)$ 且相互独立, 因此 $\mu = (0, \dots, 0)^T = 0_n$
 $Var(Z_i) = 1, Cov(Z_i, Z_j) = 0 (i \neq j)$

正态总体的抽样分布

$$\Sigma = \begin{pmatrix} 1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 1 \end{pmatrix} = I_n \rightarrow Z \sim N_n(0, I_n)$$

取一 n 阶正交矩阵 $A = (a_{ij})_{n \times n}$, 其中第 n 行元素均为 $\frac{1}{\sqrt{n}}$, 即形如

$\begin{pmatrix} any & \cdots & any \\ \vdots & \ddots & \vdots \\ \frac{1}{\sqrt{n}} & \cdots & \frac{1}{\sqrt{n}} \end{pmatrix}$ 的矩阵 (any取值需要满足正交矩阵的要求)。

这样的矩阵有以下特性: $A^T A = A A^T = I_n$

等价条件:

- A 的行/列向量构成 R_n 的一组标准正交基 (两两正交且长度为1)
- $A^{-1} = A^T$
- 保持内积和长度不变: $\|Ax\| = \|x\|, (Ax)^T(Ay) = x^T y$

正态总体的抽样分布

作正交变换 $Y = AZ$, 其中

$$Y = (Y_1, Y_2, \dots, Y_n)^T, Z = (Z_1, Z_2, \dots, Z_n)^T$$

由于 $Y_i = \sum_{j=1}^n a_{ij}Z_j (i = 1, 2, \dots, n)$, 故 $Y_1, Y_2, \dots, Y_n$ 也服从正态分布。

由 $Z \sim N_n(0, I_n)$ 知, $E(Y) = E(AZ) = AE(Z) = 0$

$$Cov(AZ, AZ) = ACov(Z, Z)A^T = AEnA^T = En$$

$$D(Y) = Cov(Y, Y) = Cov(AZ, AZ) = ACov(Z, Z)A^T = AEnA^T = En$$

由正交矩阵的性质, 故 $Y_1, Y_2, \dots, Y_n$ 两两不相关, 而且 $Y_i \sim N(0, 1) (i = 1, 2, \dots, n)$ 。

又由于 $Y = (Y_1, Y_2, \dots, Y_n)^T$ 是由 $Z = (Z_1, Z_2, \dots, Z_n)^T$ 经过线性变换而得到的, 于是由 $Y_1, Y_2, \dots, Y_n$ 两两不相关可推得 $Y_1, Y_2, \dots, Y_n$ 相互独立。

正态总体的抽样分布

$$\text{而 } Y_n = \sum_{j=1}^n a_{nj} Z_j = \sum_{j=1}^n \frac{1}{\sqrt{n}} Z_j = \sqrt{n} \bar{Z}$$

于是

$$\sum_{i=1}^n Y_i^2 = Y^T Y = (AZ)^T (AZ) = Z^T (A^T A) Z = Z^T I_n Z = Z^T Z = \sum_{i=1}^n Z_i^2$$

$$\frac{(n-1)S^2}{\sigma^2} = \sum_{i=1}^n Z_i^2 - n\bar{Z}^2 = \sum_{i=1}^n Y_i^2 - Y_n^2 = \sum_{i=1}^{n-1} Y_i^2$$

由于 $Y_1, Y_2, \dots, Y_{n-1}$ 相互独立, 且 $Y_i \sim N(0, 1) (i = 1, 2, \dots, n-1)$,

$$\therefore \sum_{i=1}^{n-1} Y_i^2 \sim \chi^2(n-1)$$

$$\therefore \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

正态总体的抽样分布

举个例子： $n = 3$, 要证明 $\frac{2S^2}{\sigma^2} \sim \chi^2(2)$

$$Z = \begin{pmatrix} Z_1 \\ Z_2 \\ Z_3 \end{pmatrix}, \text{取正交矩阵 } A = \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{6}} & -\frac{2}{\sqrt{6}} \\ \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} \end{pmatrix}, \text{则 } Y = AZ =$$

$$\begin{pmatrix} \frac{Z_1 - Z_2}{\sqrt{2}} \\ \frac{Z_1 + Z_2 - 2Z_3}{\sqrt{6}} \\ \frac{Z_1 + Z_2 + Z_3}{\sqrt{3}} = \sqrt{3}\bar{Z} \end{pmatrix}, \text{由于 } Z_i \sim N(0,1), \text{ 不难计算 } Y_i \sim N(0,1) \text{ 且相互独立,}$$

$$\sum_{i=1}^3 Y_i^2 = \sum_{i=1}^3 Z_i^2, 3\bar{Z}^2 = Y_3^2 \rightarrow$$

$$\sum_{i=1}^3 (Z_i - \bar{Z})^2 = \sum_{i=1}^3 Z_i^2 - 3\bar{Z}^2 = \sum_{i=1}^3 Y_i^2 - Y_3^2 = Y_1^2 + Y_2^2 \sim \chi^2(2)$$

正态总体的抽样分布

(3) 证明：设 $X_1, \dots, X_n$ 是总体 $N(\mu, \sigma^2)$ 的样本， $\bar{X}, S^2$ 分别是样本均值与样本方差，则有： $\bar{X}$ 与 S^2 独立

$\because \bar{X} = \sigma \bar{Z} + \mu = \frac{\sigma}{\sqrt{n}} Y_n + \mu$ 只依赖于 Y_n

而 $S^2 = \frac{\sigma^2}{n-1} \sum_{i=1}^{n-1} Y_i^2$ 仅依赖于 $Y_1, \dots, Y_{n-1}$

$\therefore \bar{X}$ 与 S^2 相互独立

(4) 证明：设 $X_1, \dots, X_n$ 是总体 $N(\mu, \sigma^2)$ 的样本， $\bar{X}, S^2$ 分别是样本均值与样本方差，则有： $\frac{\bar{X}-\mu}{S/\sqrt{n}} \sim t(n-1)$


由于 $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ ，记 $U = \frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \sim N(0,1)$ ，可得

$$\frac{\bar{X}-\mu}{S/\sqrt{n}} = \frac{\frac{\bar{X}-\mu}{\sigma/\sqrt{n}}}{\frac{S}{\sigma}} = \frac{U}{\sqrt{\frac{(n-1)S^2}{\sigma^2} / (n-1)}} = \frac{U}{\sqrt{\chi^2(n-1) / (n-1)}} = \sim t(n-1)$$

$$T = \frac{X}{\sqrt{\frac{\chi^2(n)}{n}}} \sim t(n)$$

思考题

1. 在江苏沛县调查 336m^2 小地老虎虫害情况的结果, 均值 $\mu = 4.73$ 头, 标准差 $\sigma = 2.63$ 头, 假设该分布为正态分布, 试问样本容量 $n = 30$ 时, 由随机抽样得到样本平均数 y 等于或小于 4.37 的概率为多少?



思考题

1. 在江苏沛县调查 336m² 小地老虎虫害情况的结果, 均值 $\mu = 4.73$ 头, 标准差 $\sigma = 2.63$ 头, 假设该分布为正态分布, 试问样本容量 $n = 30$ 时, 由随机抽样得到样本平均数 y 等于或小于 4.37 的概率为多少?

[解]总体服从 $N(4.73, 2.63^2)$, 样本容量 $n = 30$, 显然样本平均数 y 服从 $N\left(4.73, \frac{2.63^2}{30}\right) \rightarrow \frac{y-4.73}{\sqrt{\frac{2.63^2}{30}}} \sim N(0,1)$

样本平均数 y 等于或小于 4.37 的概率即 $P(y \leq 4.37)$

$$\begin{aligned} P(y \leq 4.37) &= P\left(\frac{y - 4.73}{\sqrt{\frac{2.63^2}{30}}} \leq \frac{4.37 - 4.73}{\sqrt{\frac{2.63^2}{30}}}\right) = \Phi(-0.75) \\ &= 1 - \Phi(0.75) = 1 - 0.7734 = 0.2266 \end{aligned}$$

正态总体的抽样分布

在正态总体的条件下，某些样本的常见统计量有比较简单的计算方式。

(II) 两个正态总体

定理5.3.2

设 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, 且 X 与 Y 独立, $X_1, \dots, X_{n_1}$ 是取自 X 的样本, $Y_1, \dots, Y_{n_2}$ 是取自 Y 的样本, $\bar{X}$ 和 $\bar{Y}$ 分别是这两个样本的样本均值, S_1^2 和 S_2^2 分别是这两个样本的样本方差, 则有

$$\frac{(S_1^2)/(\sigma_1^2)}{(S_2^2)/(\sigma_2^2)} \sim F(n_1 - 1, n_2 - 1)$$

若 $\sigma_1^2 = \sigma_2^2$, 则

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$

$$F = \frac{\chi^2(n_1)/n_1}{\chi^2(n_2)/n_2} \sim F(n_1, n_2)$$

$$T = \frac{\bar{X}}{\sqrt{\frac{\chi^2(n)}{n}}} \sim t(n)$$

正态总体的抽样分布

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$

把整个式子拆成三部分：

- **分子：** $\bar{X} - \bar{Y} - (\mu_1 - \mu_2)$

→ 两个样本均值之差，减去理论差值（通常设为0）

- **分母：** 标准误（Standard Error）

- 先算“合并方差”：

$$s_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

→ 这是“池化方差”，把两个样本的方差合起来

- 再乘上 $\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$

→ 这是“两组数据的精度组合”

- **整体：** 这个比值服从 **t 分布**，自由度是 $n_1 + n_2 - 2$

正态总体的抽样分布总结

(I) 一个正态总体

来自一个正态总体的一组样本数据

- 样本均值 $\bar{X}$ 是总体均值 μ 的一个**估计**，它本身也服从正态分布，平均是 μ ，波动比原始数据小。
- 样本方差 S^2 经过标准化后，服从卡方分布，自由度是样本量减1。
- 样本均值和样本方差这两个统计量，在正态分布下是**互不影响的**。
- 当不知道总体标准差时，用样本标准差构造的比值服从 t 分布。

(II) 两个正态总体

- 来自不同的正态总体的两组样本数据的方差比，除以各自的真实方差，服从 F 分布，自由度是两组样本数据量减1。
- 来自方差相同的不同正态总体的两组样本数据，其均值之差除以“基于两组样本合并计算出的标准误差”，服从自由度为两组样本量之和减2的 t 分布。

正态总体的抽样分布

例5.3.1 设 X_1, X_2, X_3, X_4 是来自正态总体 $N(0,9)$ 的样本 $Y = a(X_1 - X_2)^2 + b(3X_3 + 4X_4)^2$ ，问当 a, b 各为多少时，统计量 Y 服从 $\chi^2(2)$ 分布？



正态总体的抽样分布

例5.3.1 设 X_1, X_2, X_3, X_4 是来自正态总体 $N(0,9)$ 的样本 $Y = a(X_1 - X_2)^2 + b(3X_3 + 4X_4)^2$, 问当 a, b 各为多少时, 统计量 Y 服从 $\chi^2(2)$ 分布?

[解]

$$X_1 - X_2 \sim N(0, 2 * 3^2), \text{ 即 } \frac{X_1 - X_2}{3\sqrt{2}} \sim N(0,1)$$

$$3X_3 + 4X_4 \sim N(0, 25 * 3^2), \text{ 即 } \frac{3X_3 + 4X_4}{15} \sim N(0,1)$$

$$\text{根据 } \chi^2(2) \text{ 分布的定义可知 } Y = \left(\frac{X_1 - X_2}{3\sqrt{2}} \right)^2 + \left(\frac{3X_3 + 4X_4}{15} \right)^2 \sim \chi^2(2)$$

$$\text{即 } Y = \frac{1}{18} (X_1 - X_2)^2 + \frac{1}{225} (3X_3 + 4X_4)^2 \sim \chi^2(2)$$

$$\therefore a = \frac{1}{18}, b = \frac{1}{225}$$

正态总体的抽样分布

例5.3.2 设随机变量 X 和 Y 相互独立且都服从正态分布 $N(0,9)$, 而 $X_1, X_2, \dots, X_9$ 和 $Y_1, Y_2, \dots, Y_9$ 分别是来自总体 X 和 Y 的简单随机样本, 则统计量 $U = \frac{X_1 + X_2 + \dots + X_9}{\sqrt{Y_1^2 + Y_2^2 + \dots + Y_9^2}}$ 服从什么分布?

正态总体的抽样分布

例5.3.2 设随机变量 X 和 Y 相互独立且都服从正态分布 $N(0,9)$, 而 $X_1, X_2, \dots, X_9$ 和 $Y_1, Y_2, \dots, Y_9$ 分别是来自总体 X 和 Y 的简单随机样本, 则统计量 $U = \frac{X_1 + X_2 + \dots + X_9}{\sqrt{Y_1^2 + Y_2^2 + \dots + Y_9^2}}$ 服从什么分布?

[解] 令 $W_i = \frac{X_i}{3}, S_i = \frac{Y_i}{3}, i = 1, 2, \dots, 9$, 则 $W_i \sim N(0,1), S_i \sim N(0,1)$

$$W = W_1 + W_2 + \dots + W_9 \sim N(0, 3^2)$$

$$S = S_1^2 + S_2^2 + \dots + S_9^2 \sim \chi^2(9)$$

$$\therefore U = \frac{X_1 + X_2 + \dots + X_9}{\sqrt{Y_1^2 + Y_2^2 + \dots + Y_9^2}} = \frac{W_1 + W_2 + \dots + W_9}{\sqrt{S_1^2 + S_2^2 + \dots + S_9^2}} = \frac{W}{\sqrt{S}} = \frac{\frac{W}{3}}{\sqrt{\frac{S}{9}}}$$

$$\because \frac{W}{3} \sim N(0,1), S \sim \chi^2(9) \quad \therefore U \sim t(9)$$

正态总体的抽样分布

例5.3.3 设总体 $X \sim N(0, 22)$, $X_1, X_2, \dots, X_{15}$ 是来自总体 X 的样本, 则统计量 $Y = \frac{2(X_1^2 + X_2^2 + \dots + X_5^2)}{X_6^2 + X_7^2 + \dots + X_{15}^2}$ 服从什么分布?



正态总体的抽样分布

例5.3.3 设总体 $X \sim N(0, 2^2)$, $X_1, X_2, \dots, X_{15}$ 是来自总体 X 的样本, 则统计量 $Y = \frac{2(X_1^2 + X_2^2 + \dots + X_5^2)}{X_6^2 + X_7^2 + \dots + X_{15}^2}$ 服从什么分布?

[解] $X_i \sim N(0, 2^2) \rightarrow \frac{X_i}{2} \sim N(0, 1)$

$$F = \frac{\chi^2(n_1)/n_1}{\chi^2(n_2)/n_2} \sim F(n_1, n_2)$$

$$\therefore S_1^2 = \left(\frac{X_1}{2}\right)^2 + \left(\frac{X_2}{2}\right)^2 + \dots + \left(\frac{X_5}{2}\right)^2 \sim \chi^2(5)$$

$$S_2^2 = \left(\frac{X_6}{2}\right)^2 + \left(\frac{X_7}{2}\right)^2 + \dots + \left(\frac{X_{15}}{2}\right)^2 \sim \chi^2(10)$$

$$\therefore Y = \frac{2(X_1^2 + X_2^2 + \dots + X_5^2)}{X_6^2 + X_7^2 + \dots + X_{15}^2} = \frac{2S_1^2}{S_2^2} = \frac{\frac{S_1^2}{5}}{\frac{S_2^2}{10}} \sim F(5, 10)$$